

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

Кафедра: КБ-4 «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта»

Лабораторная работа №1 по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Выполнил:

Морин А. А.

Группа:

ББМО-01-23

Скопируем проект по ссылке в локальную среду выполнения и сменим директорию исполнения

```
[ ] url = 'https://github.com/ewatson2/EEL6812_DeepFool_Project'
    !git clone $url deepfool
%cd /content/deepfool

Cloning into 'deepfool'...
    remote: Enumerating objects: 96, done.
    remote: Counting objects: 100% (3/3), done.
    remote: Compressing objects: 100% (2/2), done.
    remote: Total 96 (delta 2), reused 1 (delta 1), pack-reused 93 (from 1)
    Receiving objects: 100% (96/96), 33.99 MiB | 15.27 MiB/s, done.
    Resolving deltas: 100% (27/27), done.
    /content/deepfool
```

Выполним импорт библиотек

```
import numpy as np
import json,torch
from torch.utils.data import DataLoader, random_split
from torchvision import datasets, models
from torchvision.transforms import transforms

from models.project models import FC_500_150, LeNet_CIFAR, LeNet_MNIST, Net
from utils.project utils import get_clip_bounds, evaluate_attack, display_attack
```

Установим случайное рандомное значение в виде переменной rand_seed для варианта 18

Используем в качестве устройства видеокарту

```
device = torch.device("cuda:0" if torch.cuda.is_available() else "cpu")
```

Загрузим датасет MNIST с параметрами mnist_mean = 0.5, mnist_std = 0.5, mnist_dim = 28

```
mnist_mean = 0.5
mnist_std = 0.5
mnist_jtd = mnist_min.to(device)
mnist_man = mnist_min.to(device)
mnist_jtd = transforms.Compose([ transforms.ToTensor(), transforms.Normalize( mean-mnist_mean, std-mnist_std)])
mnist_tf = transforms.Compose([ transforms.Normalize( mean-0.0, std-np.divide(1.0, mnist_std)), transforms.Normalize( mean-np.multiply(-1.0, mnist_std)])
mnist_tf inv = transforms.Compose([ transforms.Normalize( mean-0.0, std-np.divide(1.0, mnist_std)), transforms.Normalize( mean-np.multiply(-1.0, mnist_std)])
mnist_tf inv = transforms.Compose([ transforms.Normalize( mean-0.0, std-np.divide(1.0, mnist_std)), transforms.Normalize( mean-np.multiply(-1.0, mnist_std))
mnist_tf inv = transforms.Compose([ transforms.Normalize( mean-np.multiply(-1.0, mnist_std)))
mnist_test = datasets.NultsT(root='datasets/mnist', train=false, download=True, transform-mnist_tf_train)
mnist_test = datasets.NultsT(root='datasets/mnist', train=false, download=True, transform-mnist_tf)

Downloading http://yann.lecun.com/exdb/mnist/train-images-idx3-ubyte.gz

pownloading https://ossci-datasets.3i.amazonaws.com/mnist/train-images-idx3-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-images-idx3-ubyte.gz

Downloading http://yann.lecun.com/exdb/mnist/train-labels-idx1-ubyte.gz

pownloading https://yann.lecun.com/exdb/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-datasets.si.amazonaws.com/mnist/train-labels-idx1-ubyte.gz

Downloading https://ossci-dat
```

Загрузим датасет CIFAR-10 с параметрами cifar_mean = [0.491, 0.482, 0.447] cifar_std = [0.202, 0.199, 0.201] cifar_dim

```
cifar_mean = [0.491, 0.482, 0.447]
cifar_std = [0.282, 0.199, 0.201]
cifar_std = [0.282, 0.199, 0.201]
cifar_sin, cifar_max = get_clip_bounds(cifar_mean, cifar_std, cifar_din)
cifar_sin, cifar_max = get_clip_bounds(cifar_mean, cifar_std, cifar_din)
cifar_sin = cifar_max.to(device)
cifar_sex = cifar_max.to(device)
cifar_sex = cifar_max.to(device)
cifar_tf = transforms.Compose([ transforms.Norms.Normalize( mean-cifar_mean, std-cifar_std)])
cifar_tf = transforms.Compose([ transforms.Norms.Normalize( mean-cifar_mean, std-cifar_std)])
cifar_tf = transforms.Compose([ transforms.Normalize( mean-cifar_mean, std-cifar_std)])
cifar_tf = datasets.CIFAR10(root='datasets/cifar_10', transforms.Normalize( mean-p.multiply(-1.0, cifar_mean), std-[1.0, 1.0, 1.0]))
cifar_teap = datasets.CIFAR10(root='datasets/cifar_10', train=False, download=True, transforms-cifar_tf_train)
cifar_teat = datasets.CIFAR10(root='datasets/cifar_10', train=False, download=True, transform=cifar_tf)
cifar_classes = ['airplane', 'iurlomobile', 'bird', 'cat', 'deer', 'deer', 'deer', 'frog', 'horse', 'ship', 'truck']

Downloading https://neac.s.tomoto.edu/who/z/cifar_10-python.tar.gz to datasets/cifar-10/cifar-10-python.tar.gz to datasets/cifar-10-python.tar.gz to da
```

Выполним настройку и загрузку DataLoader batch_size = 64 workers = 4

```
batch_size = 64
workers = 4

mnist_loader_train = DataLoader(mnist_train, batch_size=batch_size, shuffle=True, num_workers=workers)
mnist_loader_val = DataLoader(mnist_val, batch_size=batch_size, shuffle=False, num_workers=workers)
mnist_loader_test = DataLoader(mnist_test, batch_size=batch_size, shuffle=False, num_workers=workers)
cifar_loader_train = DataLoader(cifar_train, batch_size=batch_size, shuffle=True, num_workers=workers)
cifar_loader_val = DataLoader(cifar_val, batch_size=batch_size, shuffle=False, num_workers=workers)
cifar_loader_test = DataLoader(cifar_test, batch_size=batch_size, shuffle=False, num_workers=workers)
num_workers=workers)
```

Загрузим и оценим стойкость модели Network-In-Network Model к FGSM и DeepFool атакам на основе датасета CIFAR-10

```
fgsm_eps = 0.2

model = Net():to(device)

mo
```

Загрузим и оценим стойкость модели LeNet к FGSM и DeepFool атакам на основе датасета CIFAR-10

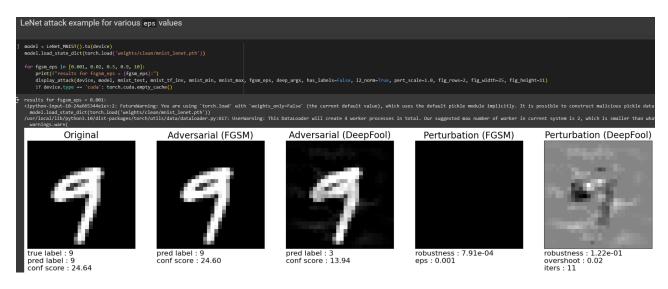
```
fgsm_eps = 0.1

model = teNet_CITAK().to(device)

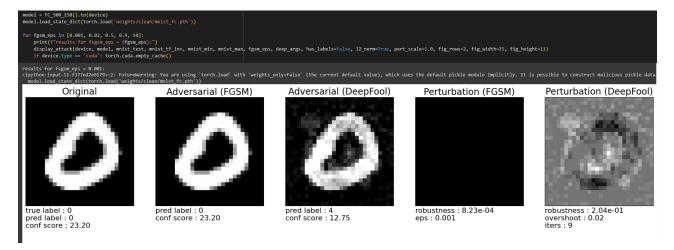
model = teNet_CITAK().to
```

Выполним оценку атакующих примеров для сетей:

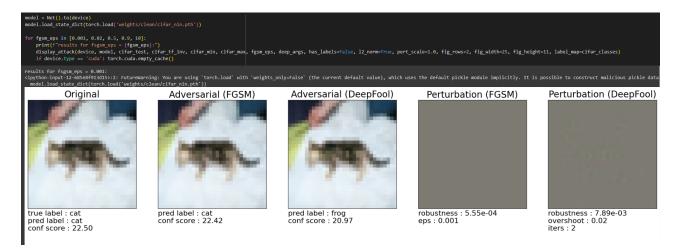
LeNet на MNIST для $fgsm_eps = (0.001, 0.02, 0.5, 0.9, 10)$



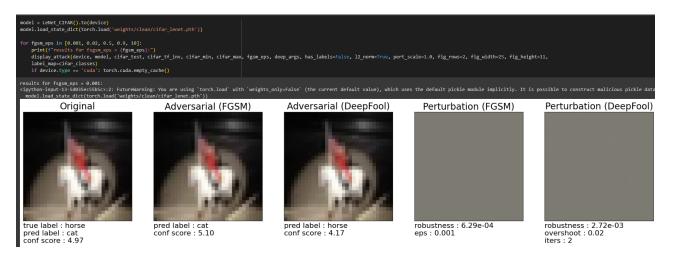
FCNet на MNIST для $fgsm_eps = (0.001, 0.02, 0.5, 0.9, 10)$



Network-in-Network на CIFAR для fgsm_eps = (0.001, 0.02, 0.5, 0.9, 10)



LeNet на CIFAR для $fgsm_eps = (0.001, 0.02, 0.5, 0.9, 10)$



Вывод.

Анализируя результаты эксперимента, можно сделать вывод, что с увеличением параметра **fgsm_eps** количество шума на изображениях возрастает. Это явление свидетельствует о том, что изображения становятся более искажёнными, и модель демонстрирует большую подверженность ошибкам в процессе работы.

Иными словами, устойчивость модели к атакам снижается с повышением значения **fgsm_eps**: чем выше этот параметр, тем легче атаке ввести модель в заблуждение и спровоцировать некорректные предсказания.

На диапазоне значений 0.001, 0.02, 0.5, 0.9, 10, модели показывают следующие результаты:

- LeNet + MNIST начинает давать ложные предсказания на значении 0.02;
- FC + MNIST аналогично;
- NiN + CIFAR начинает давать ложные предсказания на значении 0.5;
- LeNet + CIFAR на значении 0.02.

На основе этого можно сделать вывод о том, что модель NiN наиболее устойчива к атаке FGSM.